
UNIVERSIDADE FEDERAL DE OURO PRETO
DEPARTAMENTO DE CIÊNCIA DE COMPUTAÇÃO
PROCESSAMENTO DIGITAL DE IMAGENS

Projeto de Pesquisa

PARKING OCCUPANCY DETECTION

Alunos:

Caio Silas de Araujo Amaro

Mauro Lúcio Afonso Paulino dos Santos
Filho

Rômulo Júnio Vieira Rocha

Resumo

O projeto de pesquisa "Detecção de Ocupação de Estacionamento" da Universidade Federal de Ouro Preto aborda o desafio do congestionamento urbano e a falta de vagas de estacionamento mediante o desenvolvimento de um sistema de detecção de ocupação de vagas utilizando técnicas de Processamento Digital de Imagens (PDI) e aprendizado de máquina. O objetivo é criar uma rede neural que, por meio de imagens, identifique se uma vaga de estacionamento está ocupada ou livre. O sistema se baseia em visão computacional e aprendizado profundo, utilizando algoritmos como Redes Neurais Convolucionais (CNNs) para analisar e classificar imagens de estacionamentos. A eficiência do sistema é avaliada com base na precisão da classificação e no tempo de processamento. O trabalho revisa a literatura sobre o uso de tecnologias avançadas para a detecção de ocupação de estacionamento e compara diferentes abordagens, incluindo o uso de sensores físicos e métodos baseados em aprendizado de máquina.

1 Introdução

A crescente urbanização e o aumento no número de veículos estão exacerbando a necessidade de vagas de estacionamento em cidades ao redor do mundo. Esse desafio é particularmente acentuado em áreas urbanas densamente povoadas, onde a falta de espaço adequado para estacionar pode resultar em frustração para os motoristas. No Brasil, esse problema é evidente em locais como centros comerciais e empresariais, onde a competição por vagas é intensa e muitas vezes leva a congestionamentos e atrasos.

Processamento Digital de Imagens (PDI) é uma área da ciência da computação focada na análise, modificação e interpretação de imagens digitais. As técnicas de PDI permitem a transformação de imagens para melhorar sua qualidade, realçar características específicas, ou extrair dados importantes. Isso inclui operações como filtragem, segmentação, detecção de bordas e reconhecimento de padrões Umbaugh 2022

A detecção de ocupação de estacionamento é uma técnica de processamento de imagem que visa identificar, por meio de algoritmos computacionais, se um veículo está ocupando uma vaga específica em uma imagem. Esse método requer que o algoritmo seja capaz de distinguir o que constitui uma vaga de estacionamento, incluindo seus limites, e de diferenciar entre espaços vazios e aqueles preenchidos por um veículo. O processamento de imagem envolve a extração de características das imagens e sua utilização para alimentar algoritmos de aprendizado de máquina. A eficiência do sistema é avaliada com base na precisão da classificação e no tempo de processamento, comparando diferentes algoritmos e ajustando hiperparâmetros para otimizar o desempenho. Embora sensores ultrassônicos também possam ser usados para detectar a ocupação das vagas, eles são geralmente menos favoráveis em termos de custo e complexidade comparados à abordagem baseada em aprendizado profundo Farley, Ham e Hendra 2021.

Os métodos tradicionais de detecção de ocupação de estacionamento costumam utilizar sensores físicos, como ultrassom, laços indutivos, infravermelhos e sinalização magnética. Embora esses sensores sejam confiáveis, eles enfrentam desafios significativos em grande escala, como altos custos de instalação e manutenção, e a limitação de serem mais eficazes em ambientes internos ou áreas fechadas. Como resposta a esses desafios, surgem soluções mais eficientes e escaláveis através do processamento de imagem e visão computacional, esses sistemas podem integrar con-

trole inteligente da iluminação, ajustando a luminosidade com base na presença de veículos, pedestres ou ciclistas, promovendo eficiência energética. Em resumo, o processamento de imagem representa uma alternativa econômica e eficiente aos métodos baseados em sensores físicos, possibilitando soluções mais inteligentes e adaptáveis para a detecção de ocupação de estacionamento Chen et al. 2020.

Na detecção de ocupação de estacionamento, a tecnologia se baseia principalmente em visão computacional e aprendizado de máquina para tornar o processo mais inteligente e eficiente. A visão computacional analisa imagens tiradas por câmeras de estacionamento para identificar se uma vaga está ocupada ou livre, utilizando técnicas como filtragem e segmentação para separar os veículos das vagas. Redes Neurais Convolucionais (CNNs) são especialmente úteis aqui, pois conseguem aprender e reconhecer padrões complexos nas imagens, como a presença de um carro em uma vaga. Essas redes são treinadas com muitas imagens para melhorar a precisão da detecção. Outras técnicas de aprendizado profundo também ajudam a refinar essa análise, garantindo que o sistema funcione de forma rápida e confiável, proporcionando uma solução prática e moderna para gerenciar vagas de estacionamento Vilela 2020 , Oliveira et al. 2020.

2 Objetivos

O objetivo geral deste trabalho é criar um exemplo simples e funcional de detecção de ocupação de vagas de estacionamento utilizando técnicas de processamento de imagem.

Os objetivos específicos são:

- Desenvolver uma rede neural capaz de identificar, com base em imagens, se uma vaga de estacionamento está ocupada ou livre.
- Utilizar um conjunto de dados de imagens de vagas de estacionamento para treinar a rede, garantindo que ela aprenda a distinguir entre vagas ocupadas e vagas livres.
- Implementar técnicas básicas de processamento de imagem, como filtragem e segmentação, para preparar e aprimorar as imagens para o treinamento da rede neural.
- Avaliar o desempenho da rede neural em termos de precisão e eficácia na detecção de ocupação das vagas de estacionamento.

- Documentar o processo de desenvolvimento e os resultados obtidos, fornecendo uma visão clara sobre como o sistema pode ser aplicado e melhorado.

3 Estado da Arte

O problema abordado neste trabalho é a detecção de ocupação de vagas de estacionamento utilizando processamento de imagem. Para fundamentar teoricamente esta abordagem, é importante explorar conceitos chave como visão computacional, redes neurais convolucionais (CNNs), aprendizado profundo, processamento de imagem, e técnicas de segmentação e classificação de imagens. A revisão da literatura foca na utilização dessas tecnologias para reconhecimento de padrões e objetos em imagens, especificamente no contexto da detecção de veículos em vagas de estacionamento. Este estudo busca consolidar conhecimentos sobre como as CNNs e outras técnicas de aprendizado de máquina podem ser aplicadas para desenvolver sistemas eficazes e precisos de detecção de ocupação de vagas, destacando as principais metodologias e desafios enfrentados na implementação dessas soluções.

4 Trabalhos Relacionados

Na busca por soluções eficazes para a detecção de ocupação de estacionamento, diversos estudos têm explorado tecnologias avançadas como aprendizado profundo e visão computacional. Um exemplo é o trabalho de Barseghyan (2023), que desenvolve um sistema de detecção em tempo real baseado em vídeos ao vivo. Este sistema utiliza o algoritmo YOLO (You Only Look Once), conhecido por sua eficácia na detecção de objetos, combinado com o método IoU (Intersection over Union) para identificar se as vagas estão ocupadas ou desocupadas. A pesquisa demonstra que modelos treinados com dados específicos de estacionamento apresentam uma precisão significativamente maior, e a comparação com modelos pré-treinados em conjuntos de dados como COCO reforça a importância da especificidade dos dados de treinamento para a eficácia do sistema.

Em outra abordagem, Rahman et al. (2020) investiga o uso de uma rede neural convolucional (CNN), especificamente uma variação da AlexNet chamada mAlexNet, para a detecção de vagas de estacionamento. As CNNs são amplamente reconhecidas por sua capacidade de analisar

e classificar imagens com alta precisão. Neste estudo, o modelo é treinado com imagens de vagas, tanto ocupadas quanto desocupadas, o que permite à rede aprender a distinguir entre essas condições. Embora o estudo não forneça detalhes sobre taxas de acerto ou eficiência computacional, a modificação da AlexNet sugere uma otimização para aplicações práticas em ambientes de estacionamento.

O estudo de Yamin Siddiqui et al. (2022), por sua vez, se diferencia ao utilizar a Máquina de Aprendizado Profundo Extremo (DELM) para prever a localização de vagas de estacionamento disponíveis, focando na previsão e não apenas na detecção direta. Embora similar aos outros estudos na aplicação de redes neurais, o DELM adota uma abordagem diferente ao integrar a previsão de vagas disponíveis com uma estrutura de rede neural artificial (ANN) que usa propagação feedforward e backpropagation. Enquanto os estudos anteriores, como o de Barseghyan (2023), utilizam técnicas de detecção em tempo real com dados específicos de estacionamento e modelos como YOLO, o estudo de Yamin Siddiqui et al. (2022) visa prever vagas disponíveis com uma taxa de precisão de 91,25%

No trabalho de Mendes e Cavenagli (2020), A solução proposta utiliza processamento de imagens e redes neurais convolucionais (CNN) para detectar vagas de estacionamento disponíveis, funcionando em estacionamentos com vagas adjacentes e linhas horizontais paralelas, mesmo com inclinações. O sistema captura imagens através de uma câmera, enviando-as para um servidor para análise em duas etapas: identificação de vagas livres com marcações visíveis e previsão de vagas com marcações não visíveis, usando CNN para detectar carros. Essa abordagem é adaptativa e eficiente, não necessitando de conhecimento prévio ou marcação manual das vagas. Apesar da boa precisão da Mask R-CNN, há desafios na detecção perfeita dos veículos, especialmente em condições adversas, e estratégias estão sendo desenvolvidas para melhorar a eficácia, embora o texto não forneça valores específicos de acerto ou precisão.

Na pesquisa de Oliveira et al. (2020), é abordada a detecção de vagas de estacionamento usando o PKLot Dataset, que contém 12.416 imagens em diferentes condições climáticas. O estudo visa verificar a ocupação das vagas em tempo real, considerando clima e iluminação, e seu impacto na precisão da classificação. O procedimento envolve o tratamento das imagens e a aplicação de modelos pré-treinados, como DenseNet e MobileNet, para a classificação do clima. Durante o teste, as imagens são analisadas por essas redes, e os vetores de características são combinados

e classificados com um KNN. Modelos especializados foram treinados para cada tipo de clima usando a arquitetura ResNet50, com transfer learning do ImageNet. Uma quarta ResNet50 foi treinada para classificar vagas sem considerar o clima, para avaliar o impacto da separação das imagens por clima na precisão da classificação.

A abordagem descrita no estudo de Grbić e Koch (2023) é relevante para a área de sistemas de orientação de estacionamento, pois substitui os tradicionais sensores de hardware por uma metodologia baseada em imagens, que pode ser mais econômica e flexível. A detecção automática das vagas é realizada por meio da análise de veículos e clustering em visão aérea, enquanto a classificação da ocupação é feita utilizando um classificador profundo ResNet34. O artigo destaca os desafios comuns enfrentados por sistemas baseados em visão, como variabilidade de perspectiva e obstruções, e por demonstrar robustez frente a situações de estacionamento ilegal e veículos em movimento.

O estudo de Thakur et al. (2024) apresenta um sistema baseado em redes neurais convolucionais (CNNs) que usa os modelos ResNet50 e VGG16 para detectar a ocupação de vagas com alta precisão — 98,9% para o ResNet50 e 93,4% para o VGG16. O trabalho se destaca por aplicar essas técnicas a um conjunto de dados variado, o PKLot, que inclui diferentes condições de iluminação e clima, mostrando como as CNNs podem ser eficazes em cenários do mundo real.

O artigo de Zhao, Zhang e Zhang (2020) aborda a crescente demanda por previsões precisas de ocupação de vagas de estacionamento, uma necessidade essencial para a gestão eficiente desses espaços em áreas urbanas. O estudo comparou quatro modelos preditivos: regressão linear (LR), máquina de vetor de suporte (SVM), rede neural de retropropagação (BPNN) e modelo autorregressivo integrado de médias móveis (ARIMA), utilizando dois métodos de previsão (FM1 e FM2). Dados reais de estacionamentos de diferentes tipos e escalas em Shenzhen, Xangai e Dongguan foram utilizados para avaliar o desempenho desses modelos. Os resultados indicam que a SVM, especialmente quando combinada com o método FM1, obteve o melhor desempenho geral, sendo recomendada para previsões de ocupação de grandes estacionamentos comerciais e funcionais.

5 Modelo Proposto

O modelo proposto a ser feito neste trabalho é uma adaptação do desenvolvido no artigo de Oliveira et al. (2020). O modelo utilizado neste trabalho é uma combinação das redes neurais convolucionais MobileNetV2 e DenseNet121, que são adaptadas para a tarefa de detecção de vagas de estacionamento, o modelo também inclui o uso de um classificador K-Nearest Neighbors (KNN), com número de vizinhos igual a 3. Para aprimoração, três versões modificadas da ResNet50 foram incorporadas ao modelo, cada uma com uma camada convolucional adicional de 1024 neurônios. Essas redes foram treinadas separadamente para condições meteorológicas específicas: R1 para dias ensolarados, R2 para dias chuvosos e R3 para dias nublados. A combinação dos vetores de características dessas redes possibilita uma análise mais robusta e precisa das imagens de estacionamentos.

5.1 Transferência de Aprendizado (Transfer Learning)

Ambos os modelos, MobileNetV2 e DenseNet121, foram inicialmente pré-treinados na base de dados ImageNet, que contém milhões de imagens rotuladas. A técnica de *transfer learning* foi empregada para transferir as características aprendidas para o problema específico de detecção de vagas. Durante o processo de ajuste fino (*fine-tuning*), os pesos das camadas convolucionais foram atualizados, adaptando-se ao conjunto de imagens aéreas de estacionamentos, que apresentam condições climáticas variadas, como dias ensolarados, nublados e chuvosos.

5.2 Configuração do Treinamento

As imagens utilizadas foram redimensionadas para 224x224 pixels, a fim de serem compatíveis com a entrada dos modelos. O conjunto de dados foi dividido em três condições climáticas principais: ensolarado, nublado e chuvoso. Para garantir a diversidade dos dados, aproximadamente 25% das imagens de cada clima foram amostradas aleatoriamente, resultando em uma mistura equilibrada para o treinamento.

A configuração do treinamento incluiu:

1. **Treinamento Geral:** Utilizou-se a combinação de características das redes MobileNetV2 e

DenseNet121 para treinar um classificador genérico de vagas, sem distinção climática.

2. **Treinamento Específico por Clima:** Foram treinados classificadores especializados para cada tipo de clima (ensolarado, nublado e chuvoso), usando técnicas de *fine-tuning* para otimizar o desempenho de acordo com as características específicas de cada cenário.

5.3 Detecção de Vagas e Classificação de Clima

O sistema de detecção foi dividido em duas etapas principais:

- **Classificação de Clima:** A primeira etapa consiste em classificar as imagens de acordo com as condições climáticas. Para isso, as redes MobileNetV2 e DenseNet121 foram usadas para extrair vetores de características. Esses vetores foram então concatenados e usados como entrada para um classificador KNN (*k-Nearest Neighbors*) com $k=3$, que determina o clima da imagem.
- **Classificação de Vagas:** Após a classificação climática, o sistema seleciona o modelo apropriado para detecção de vagas. Cada modelo foi treinado especificamente para um tipo de clima (ensolarado, nublado e chuvoso), garantindo maior precisão na detecção. Além disso, um modelo genérico, treinado com todas as condições climáticas, foi utilizado para avaliar o impacto da especialização climática na tarefa de detecção de vagas.

6 Experimentos

Nesta seção, detalhamos os experimentos realizados para validar o modelo proposto de detecção de vagas de estacionamento em imagens aéreas. Para isso, utilizamos os modelos MobileNetV2 e DenseNet121, combinados com um classificador KNN para a classificação das condições climáticas e ResNet50 para a detecção de vagas. Diferente do artigo base, foi implementado apenas a rede combinada e a análise dos 3 climas, sem a análise misturada (todos os climas misturados). Em seguida, realizamos uma comparação com os resultados obtidos no trabalho original, que também utilizou técnicas de transferência de aprendizado e ResNet50.

6.1 Configuração de Hardware

Os experimentos foram realizados nas seguintes configurações de hardware:

- **Processador:** AMD Ryzen 5 3600
- **Memória RAM:** 16 GB
- **Placa de Vídeo:** NVIDIA RTX 3050

Essas configurações menos potentes que as utilizadas no trabalho original, que usou uma NVIDIA GTX 1080 com 11 GB de memória dedicada e um processador Intel Core i7-6850K em uma máquina com 64 GB de memória RAM. Apesar disso, nosso modelo apresentou tempos de processamento aceitáveis e resultados de alta precisão.

6.2 Métricas de Avaliação

A avaliação dos modelos foi feita utilizando a **matriz de confusão**, sendo as métricas derivadas:

- **Acurácia:** Proporção de previsões corretas em relação ao total de previsões. Esta métrica foi usada para avaliar a eficiência global do sistema.
- **Recall (Revocação):** Capacidade do modelo de identificar corretamente as vagas ocupadas.
- **Precisão:** Capacidade do modelo de prever corretamente as vagas livres.
- **F1-Score:** A média harmônica entre precisão e recall, útil para medir o desempenho global em datasets balanceados.

6.3 Resultados

Os experimentos mostraram que nosso sistema foi capaz de detectar vagas com alta precisão em diversas condições climáticas. Os resultados foram analisados e comparados com os do trabalho original. Abaixo estão os principais resultados: Ao longo da apresentação dos resultados, foram geradas matrizes de confusão que ilustram o desempenho do modelo em diferentes condições climáticas, como dias ensolarados, nublados e chuvosos. Essas matrizes destacam a capacidade do

Tabela 1: Resultados de Desempenho do Modelo para Detecção de Vagas

Clima	Acurácia (%)	Recall (%)	Precisão (%)	F1-Score (%)
Ensolarado	99.58	99.50	99.60	99.55
Nublado	99.57	99.55	99.60	99.57
Chuvoso	99.85	99.80	99.85	99.82

modelo em prever corretamente as vagas livres e ocupadas. A Figura 1 mostra a matriz de confusão para os dias ensolarados, onde o modelo atingiu uma acurácia de 99.58%, evidenciando uma excelente performance. Já a Figura 2 apresenta os resultados para dias nublados, com uma acurácia de 99.57%, mantendo um desempenho consistente. Por fim, a Figura 3 ilustra os resultados obtidos em dias chuvosos, onde o modelo obteve sua melhor performance, com acurácia de 99.85%.

Além disso, o modelo foi capaz de identificar visualmente as vagas ocupadas e livres em uma imagem típica de estacionamento. Na Figura 4, as vagas ocupadas estão destacadas em vermelho, enquanto as vagas livres aparecem em verde, demonstrando a robustez do sistema na detecção e classificação das vagas.




Figura 1: Matriz de Confusão para dias ensolarados.




Figura 2: Matriz de Confusão para dias nublados.




Figura 3: Matriz de Confusão para dias chuvosos.

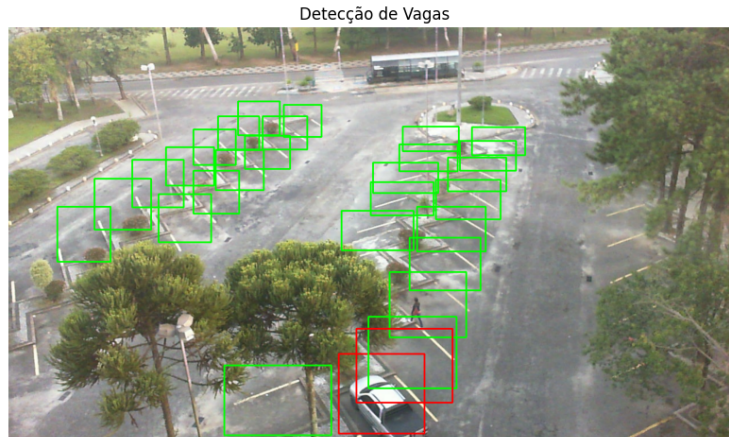


Figura 4: Identificação de vagas pelo modelo. Vagas ocupadas estão marcadas em vermelho e vagas livres em verde.

6.4 Comparação com o Trabalho Original

Nosso trabalho utilizou uma abordagem semelhante ao trabalho original no que se refere à transferência de aprendizado e ajuste fino dos modelos pré-treinados no ImageNet. Entretanto, algumas diferenças notáveis surgiram:

- **Modelos Utilizados:** O trabalho original utilizou três modelos ResNet50 especializados para cada clima e um quarto modelo misturado para testar o impacto da especialização climática. Em nossa abordagem, combinamos MobileNetV2 e DenseNet121 para a classificação do clima e utilizamos apenas a ResNet50 para a detecção de vagas.
- **Acurácia:** Embora ambos os trabalhos apresentem altos níveis de acurácia, nosso modelo se destacou em condições chuvosas (99.85% contra 95% no original).
- **Recursos Computacionais:** Nossa configuração de hardware foi inferior à do trabalho original, que utilizou uma NVIDIA GTX 1080 e uma CPU mais potente. Apesar disso, o desempenho de nosso modelo foi comparável, o que sugere que as redes MobileNetV2 e DenseNet121 são mais eficientes em termos de uso de recursos computacionais, mantendo alto desempenho.

7 Considerações finais

Em conclusão, o projeto de detecção de ocupação de vagas de estacionamento utilizando técnicas de Processamento Digital de Imagens (PDI) e aprendizado de máquina mostrou-se uma solução promissora e eficaz para enfrentar um problema urbano comum. A integração das redes MobileNetV2 e DenseNet121 proporcionou um sistema robusto, capaz de operar com alta precisão em diversas condições climáticas, especialmente em dias chuvosos, onde a acurácia atingiu seu melhor desempenho.

Mesmo com recursos computacionais limitados, o modelo demonstrou ser eficiente, sugerindo que abordagens baseadas em visão computacional podem oferecer uma alternativa mais econômica e escalável em comparação aos métodos tradicionais baseados em sensores físicos.

Referências

- Barseghyan, Laura (mai. de 2023). “Real-Time Parking Occupancy Detection”. Supervisor: Elen Vardanyan. Diss. de mestr. American University of Armenia, Zaven & Sonia Akian College of Science e Engineering.
- Chen, Lun-Chi et al. (2020). “Video-Based Parking Occupancy Detection for Smart Control System”. Em: *Applied Sciences* 10.3. ISSN: 2076-3417. DOI: [10 . 3390 / app10031079](https://doi.org/10.3390/app10031079). URL: <https://www.mdpi.com/2076-3417/10/3/1079>.
- Farley, Albertus, Hanry Ham e Hendra (2021). “Real Time IP Camera Parking Occupancy Detection using Deep Learning”. Em: *Procedia Computer Science* 179. 5th International Conference on Computer Science and Computational Intelligence 2020, pp. 606–614. ISSN: 1877-0509. DOI: [https : / / doi . org / 10 . 1016 / j . procs . 2021 . 01 . 046](https://doi.org/10.1016/j.procs.2021.01.046). URL: [https : / / www . sciencedirect . com / science / article / pii / S1877050921000533](https://www.sciencedirect.com/science/article/pii/S1877050921000533).
- Grbić, Ratko e Brando Koch (2023). “Automatic vision-based parking slot detection and occupancy classification”. Em: *Expert systems with applications* 225, p. 120147.
- Mendes, Caroline Mazetto e Willian Marrion Cavenagli (2020). “Detecção de Vagas em Estacionamento Usando Visão Computacional e Redes Neurais Convolucionais”. Em: *Anais do Computer on the Beach* 11, pp. 064–065.
- Oliveira, Lucas et al. (jan. de 2020). “Detecção Inteligente de Vagas de Estacionamento Baseado em Climats Usando Imagens Aéreas e Aprendizado Profundo”. Em: DOI: [10 . 14209 / SBRT . 2020 . 1570658218](https://doi.org/10.14209/SBRT.2020.1570658218).
- Rahman, Sayuti et al. (2020). “Convolutional Neural Network Customization for Parking Occupancy Detection”. Em: *2020 International Conference on Electrical Engineering and Informatics (ICELTICs)*, pp. 1–6. DOI: [10 . 1109 / ICELTICs50595 . 2020 . 9315509](https://doi.org/10.1109/ICELTICs50595.2020.9315509).
- Thakur, Narina et al. (2024). “Deep learning-based parking occupancy detection framework using ResNet and VGG-16”. Em: *Multimedia Tools and Applications* 83.1, pp. 1941–1964.
- Umbaugh, Scott E (2022). *Digital image processing and analysis: digital image enhancement, restoration and compression*. Crc Press.

- Vilela, Danieli Biagi (2020). “Detecção da ocupação de um ambiente a partir de dados de sensores utilizando rede neural ARTMAP Fuzzy”. Diss. de mestr. Universidade Estadual Paulista (Unesp).
- Yamin Siddiqui, Shahan et al. (2022). “Smart occupancy detection for road traffic parking using deep extreme learning machine”. Em: *Journal of King Saud University - Computer and Information Sciences* 34.3, pp. 727–733. ISSN: 1319-1578. DOI: <https://doi.org/10.1016/j.jksuci.2020.01.016>. URL: <https://www.sciencedirect.com/science/article/pii/S1319157819313928>.
- Zhao, Ziyao, Yi Zhang e Yi Zhang (2020). “A comparative study of parking occupancy prediction methods considering parking type and parking scale”. Em: *Journal of Advanced Transportation* 2020.1, p. 5624586.